



PONTIFÍCIA UNIVERSIDADE CATÓLICA DO RIO GRANDE DO SUL  
FACULDADE DE INFORMÁTICA  
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

# Aprendizado de Máquina

## Conceitos Básicos

PPGCC PUCRS

Prof. Dr. Rodrigo C. Barros



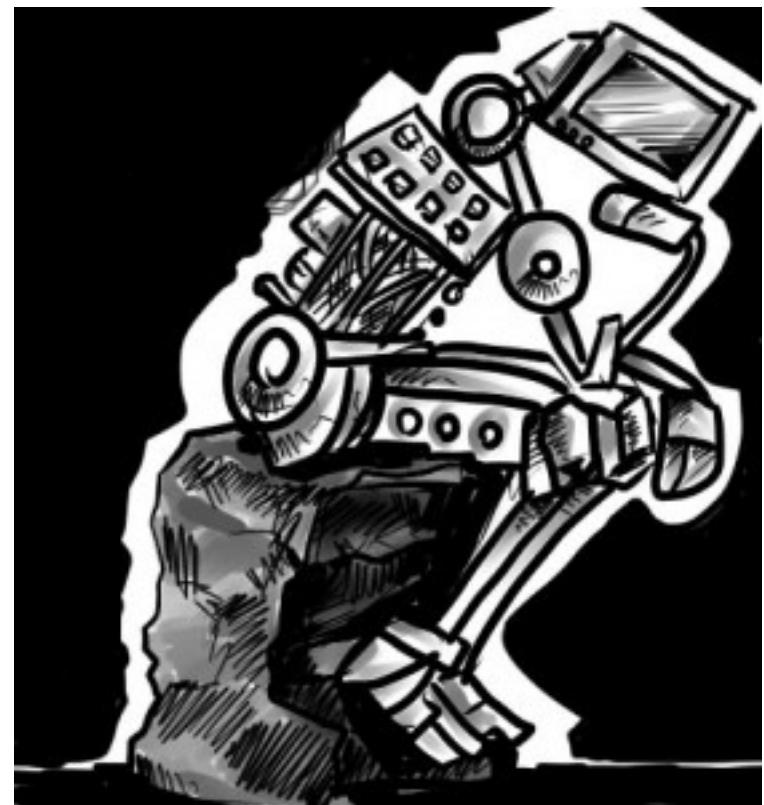
BUSINESS INTELLIGENCE AND  
MACHINE LEARNING RESEARCH GROUP

# Aula de Hoje

- Motivação
- Definições de AM
- Paradigmas de AM
- Projetando um Sistema de Aprendizado
- Informações Úteis
  - Repositórios de Dados
  - MOOCs
  - Toolboxes
  - Journals
  - Conferences

# Motivação

- Desde que os computadores foram inventados, é perguntado se eles podem aprender
- Se fosse possível entender como programá-los para aprender, o impacto seria enorme



# Motivação

- Computadores capazes de aprender poderiam:
  - Definir tratamentos mais eficazes para determinadas doenças/perfis de pacientes
  - Otimizar o consumo de energia elétrica visando redução de gastos e/ou aumento de conforto
  - Otimizar as notícias apresentadas em um jornal eletrônico de acordo com o perfil do usuário

# Motivação

“Na medida que os computadores se tornam mais sofisticados, parece inevitável que o Aprendizado de Máquina exerça um papel central em Ciência da Computação e tecnologia de computadores.”

Tom Mitchell

# Aplicações de AM

- Algoritmos de AM têm sido bem sucedidos para:
  - Identificar genes associados a determinadas doenças
  - Discriminar tecidos (saudáveis/doentes), objetos celestiais, ...
  - Identificar nichos de mercado
  - Prever a vazão de rios e nível de represas
  - Detectar uso fraudulento de cartões de crédito
  - Otimizar ações de controle em processos de produção
  - Reconhecimento facial, de voz, de assinaturas
  - Prever estrutura e função de proteínas
  - e tantas outras aplicações...

# Exemplo: ALVINN



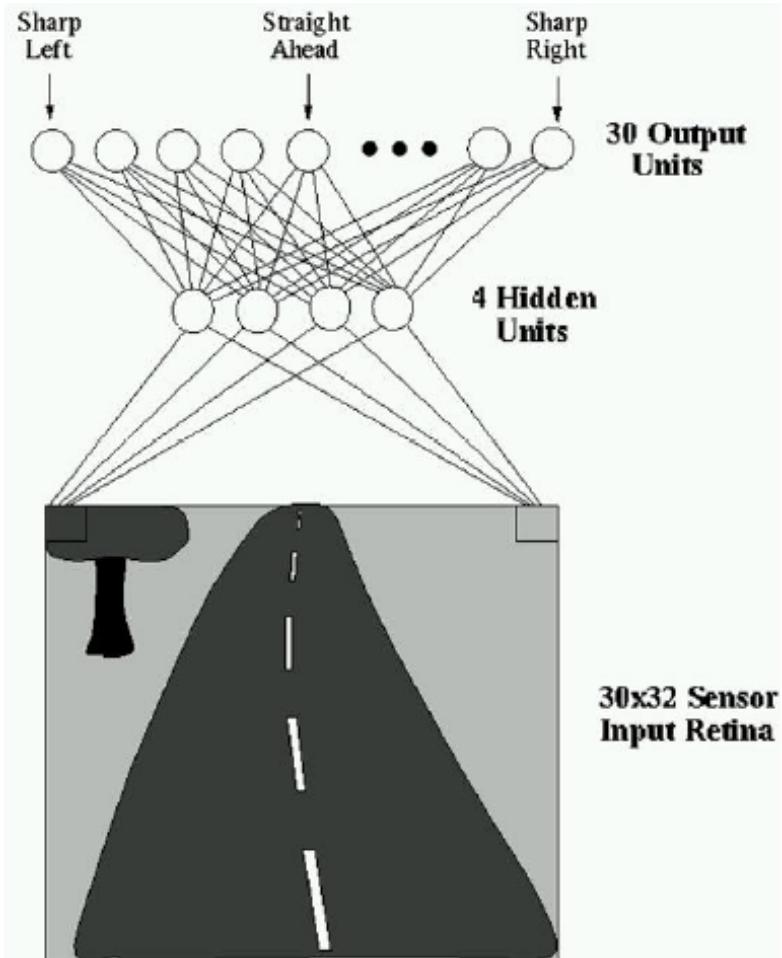
Dean Pomerleau (1989)  
CMU

# ALVINN

- Sistema automático de navegação para automóveis
  - Baseado em imagens de uma câmera onboard
  - Dirigiu a 110km/h em rodovia pública americana
    - De costa a costa em 1989 por 2850 milhas

# ALVINN

- Utiliza uma Rede Neural
  - 960 entradas
    - Matrix 30x32 derivada dos pixels da imagem
  - 4 neurônios intermediários
  - 30 neurônios de saída
    - Cada um representando um comando de direção



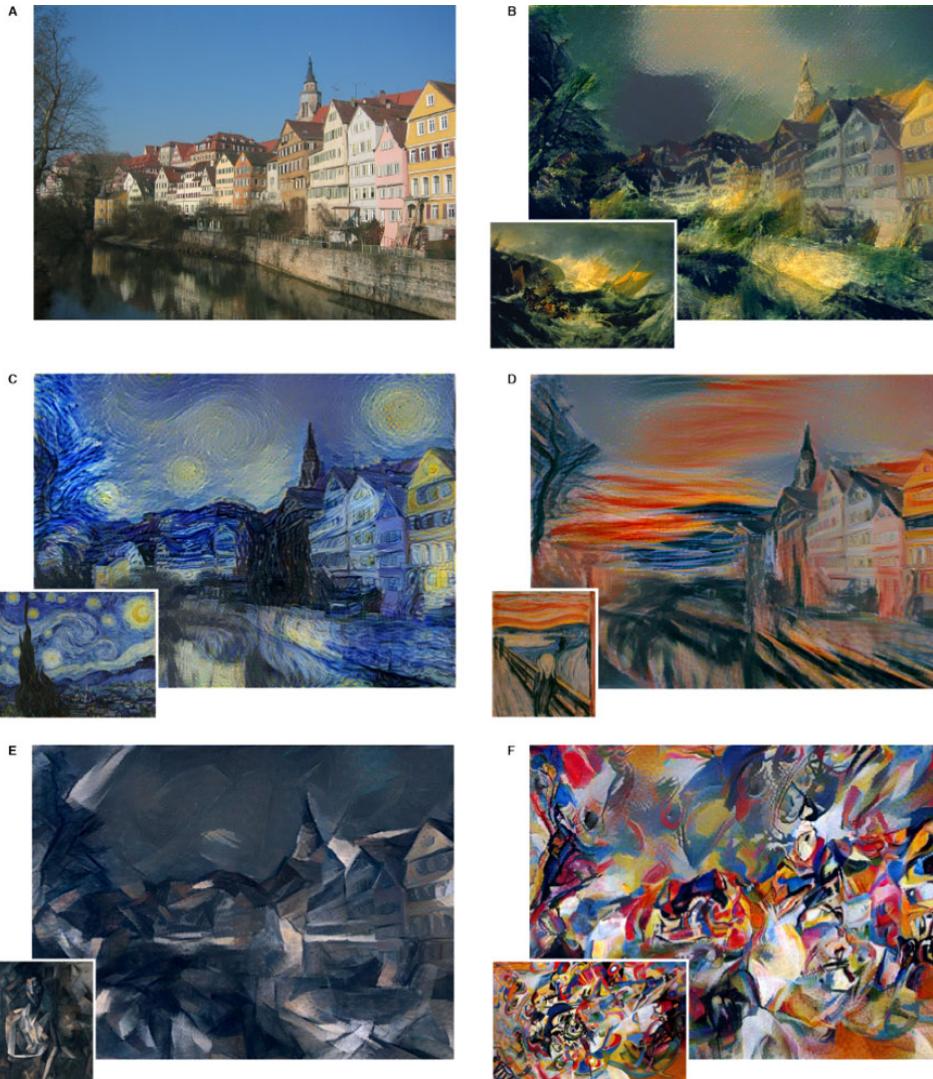
# Google Self-Driving Car



<https://www.youtube.com/watch?v=CqSDWoAhvLU>



# Captura do Estilo de Pintores Famosos



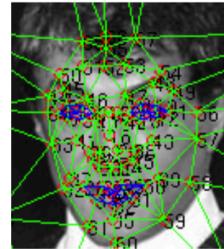
# Reconhecimento de Faces



(a)



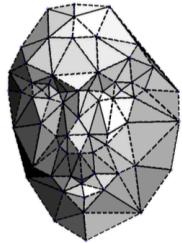
(b)



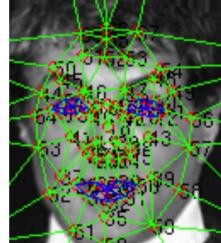
(c)



(d)



(e)



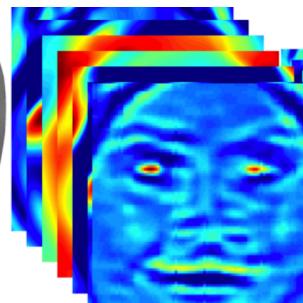
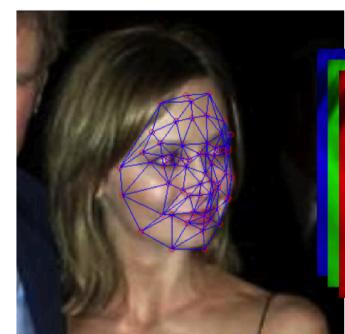
(f)



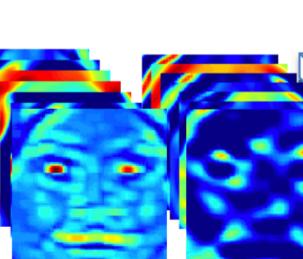
(g)



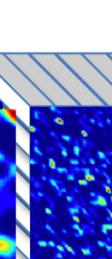
(h)



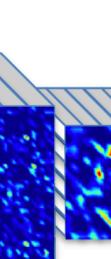
C1:  
32x11x11x3  
@142x142



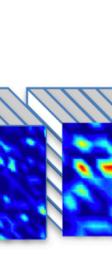
M2:  
32x3x3x32  
@71x71



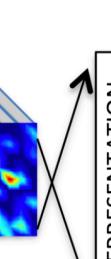
C3:  
16x9x9x32  
@63x63



L4:  
16x9x9x16  
@55x55



L5:  
16x7x7x16  
@25x25



L6:  
16x5x5x16  
@21x21



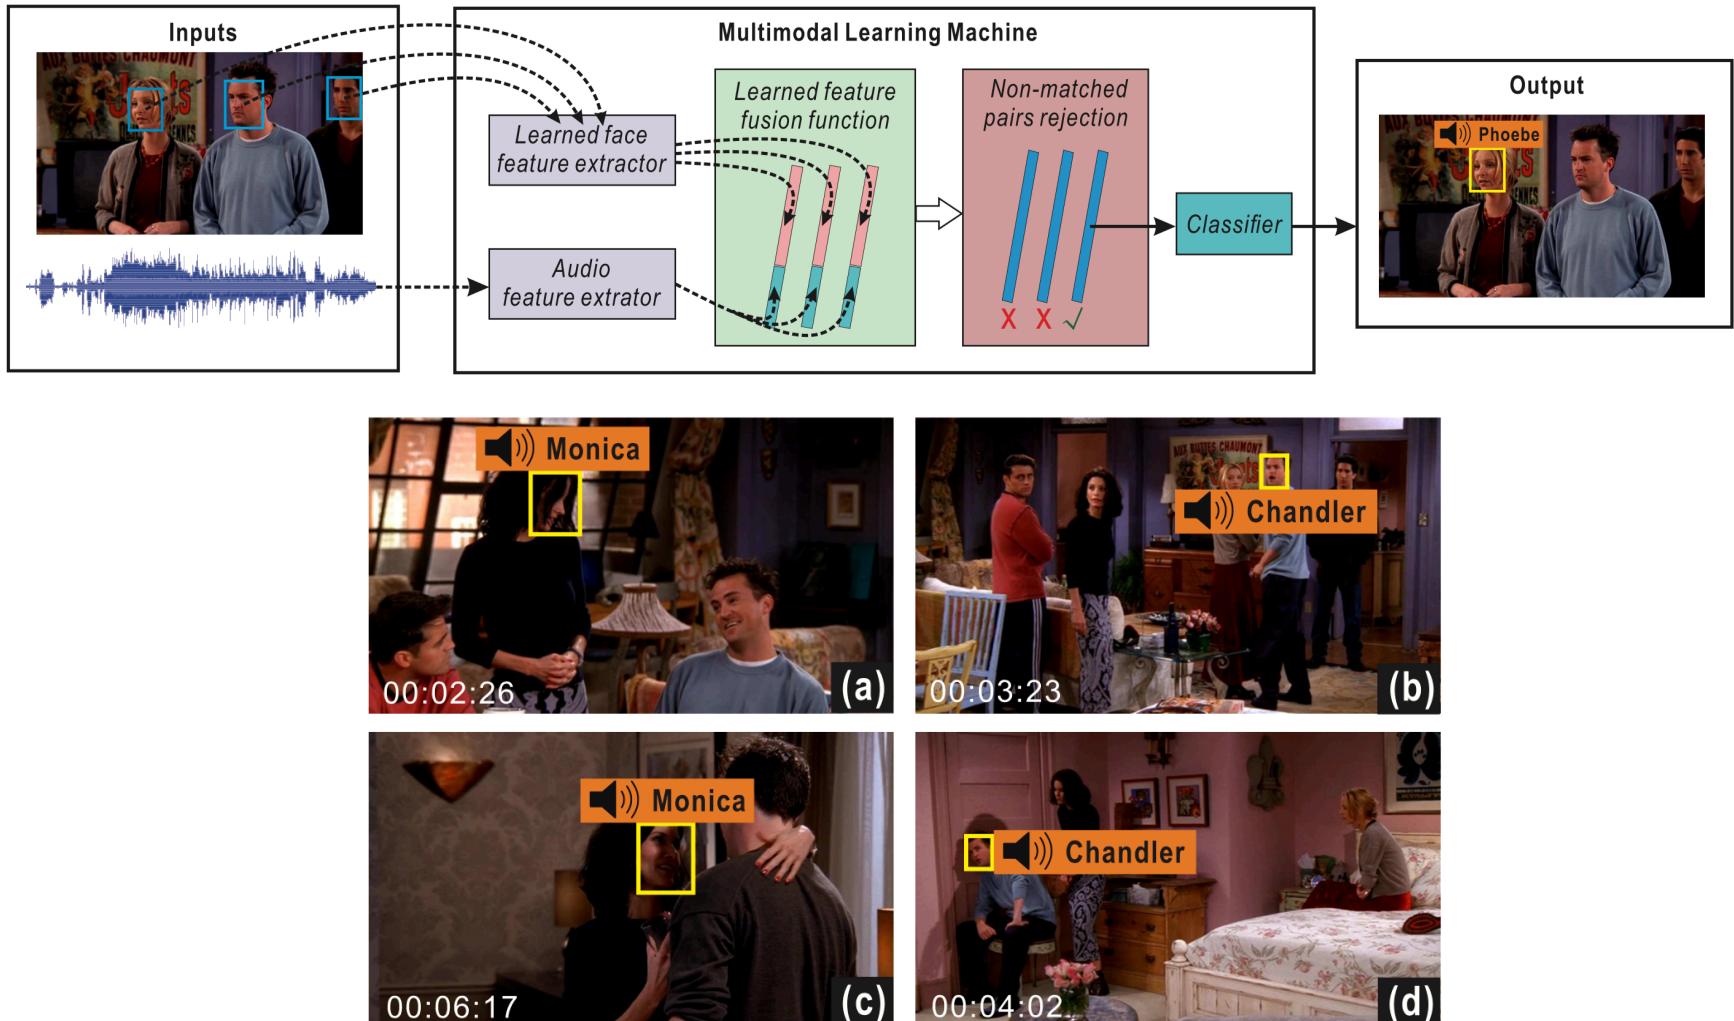
F7:  
4096d

F8:  
4030d

REPRESENTATION

SFC labels

# Reconhecimento de Faces e Fala

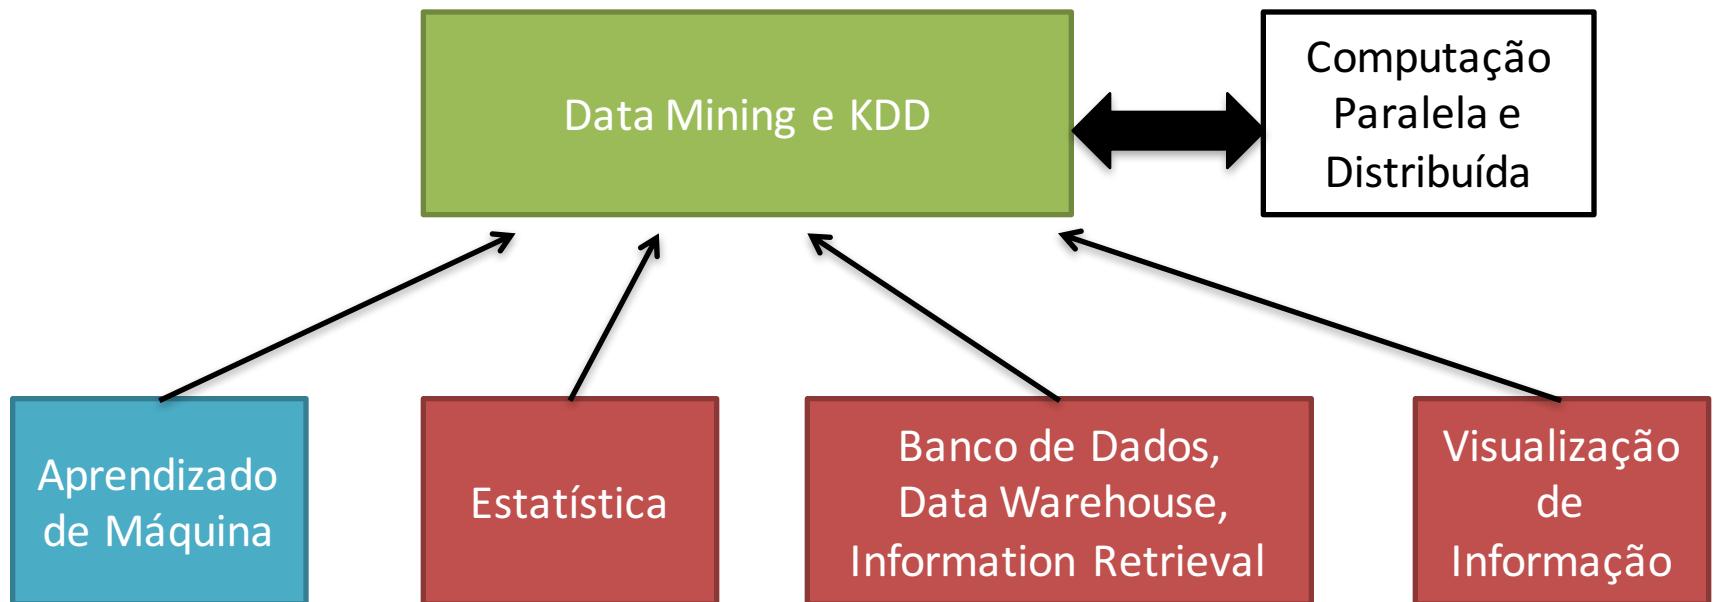


# Aplicações de AM

- Uma das áreas de aplicação mais importantes de AM têm sido descoberta de conhecimento em bases de dados (KDD)
  - Mineração de Dados (Data Mining – DM)
  - Exemplos:
    - Registros de compras em grandes supermercados
    - Registros de empréstimos financeiros
    - Registros de transações financeiras
    - Registros médicos
    - Projeto genoma
    - ...

# AM, DM e KDD

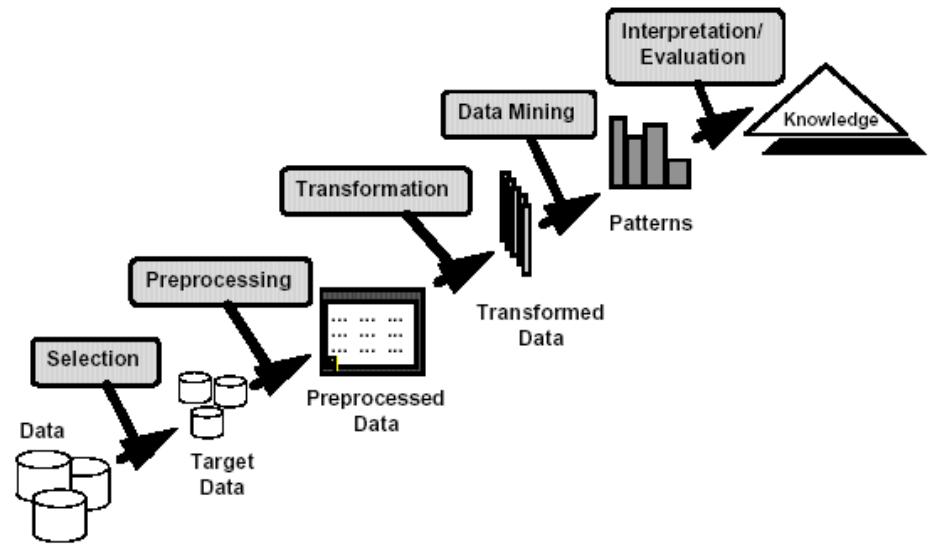
- Os termos Aprendizado de Máquina e Data Mining são muitas vezes utilizados de maneira indiscriminada, porém se referem a conceitos diferentes:



- DM é geralmente feita utilizando AM (mas nem sempre!)

# AM, DM e KDD

- Já KDD é usualmente definido como um ciclo que envolve DM
  - Formalmente, KDD é o processo não-trivial de identificar padrões **válidos, novos, potencialmente úteis e compreensíveis** em dados
    - *Advances in Knowledge Discovery and Data Mining*, Fayyad, Piatetsky-Shapiro, Smyth, and Uthurusamy, (Chapter 1), MIT Press, 1996
- Mas AM não é um sub-conjunto de DM ou KDD!!!
  - Reconhecimento de fala, voz, assinaturas, controle, robótica, ...



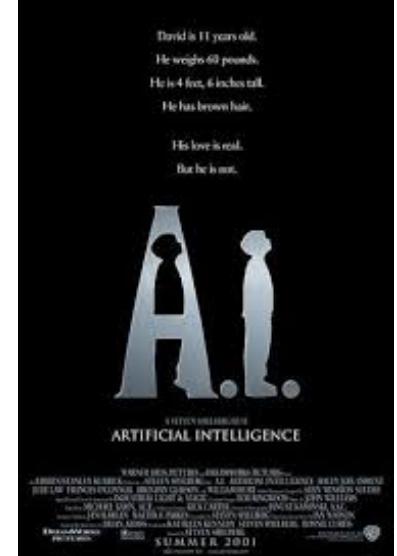
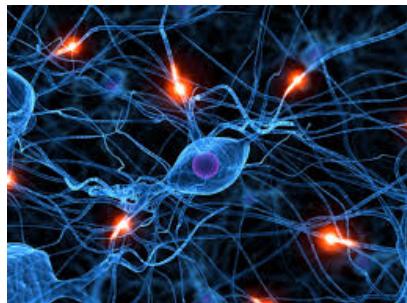
(Tan et al., 2006)

# Por que estudar AM?

- ***Esse é o momento!***
  - Vários algoritmos efetivos e eficientes estão disponíveis
  - Grande quantidade de dados disponíveis online
  - Elevada capacidade dos recursos computacionais disponíveis
  - *Data scientist is the sexiest job of the 21<sup>st</sup> Century!*  
[\(http://hbr.org/2012/10/data-scientist-the-sexiest-job-of-the-21st-century/\)](http://hbr.org/2012/10/data-scientist-the-sexiest-job-of-the-21st-century/)

# Disciplinas Relacionadas

- Inteligência Artificial
  - Mineração de Dados
  - Teoria da Informação
  - Estatística Bayesiana e Frequentista
  - Otimização
  - Estimação, Filtragem e Controle
  - Teoria da Complexidade Computacional
  - Neurociências
  - ...



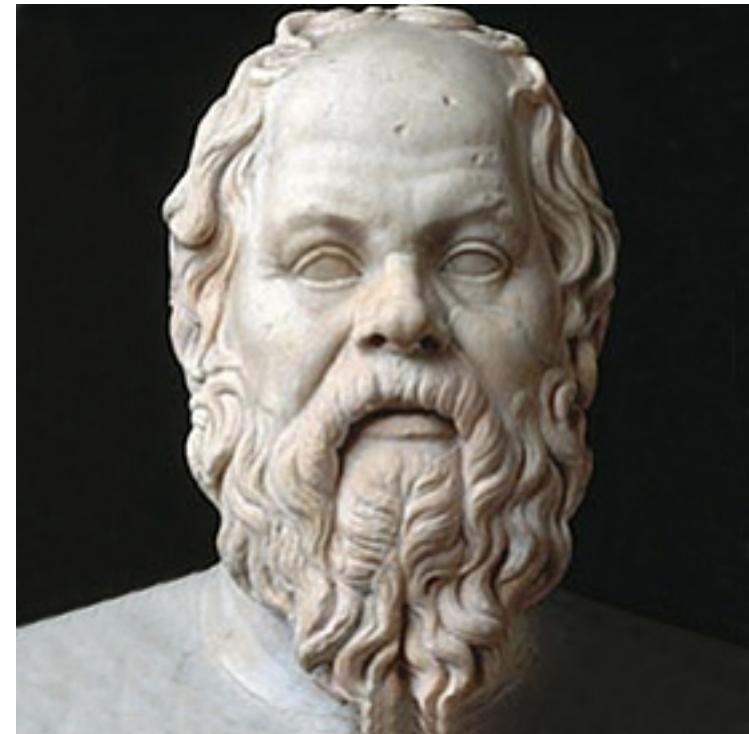
# Definições

- Definições relacionadas a aprendizado e AM
  - Uma máquina de aprendizado, definida de maneira ampla, é qualquer dispositivo cujas ações são influenciadas por **experiências anteriores** (Nilsson 1965)
  - Qualquer mudança em um sistema que o permite ter um melhor desempenho na segunda vez em que ele **repete uma mesma tarefa** (Simon 1983)
  - Modificação de uma tendência comportamental por meio de **experiência** (Webster 1984)
  - Uma melhoria na capacidade de processar informação a partir da **atividade** de processar informação (Tanimoto 1990)

# Definição de Aprendizado

Sócrates: Aprender é Recordar

(Diálogos de Platão)



# Aprendizado de Máquina

- Definição clássica (Mitchell, 1997):

“Um programa de computador é dito **aprender** a partir de uma experiência  $E$  com respeito a alguma classe de tarefas  $T$  e medida de desempenho  $P$ , se seu desempenho em tarefas de  $T$ , medido por  $P$ , melhora com a experiência  $E$ .”



## Exemplo 1

- Problema de Aprender a Jogar Xadrez
  - **Tarefa T:** jogar xadrez
  - **Medida de desempenho P:** percentagem de jogos vencidos contra adversários
  - **Experiência de treinamento E:** praticar jogando contra si próprio ou contra adversários humanos (p.ex., pela internet)

# Exemplo 2

- Problema de Filtrar SPAMs
  - **Tarefa T:** categorizar mensagens de email como *spam* ou legítima
  - **Medida de desempenho P:** percentagem de mensagens corretamente classificadas
  - **Experiência de treinamento E:** conjunto de emails manualmente rotulados por seres humanos



# Exercício 1

- Problema de reconhecimento de escrita manual
  - Tarefa T:
  - Medida de desempenho P:
  - Experiência de treinamento E:

# Exercício 2

- Problema do Veículo Autônomo
  - Tarefa T:
  - Medida de desempenho P:
  - Experiência de treinamento E:

# Exercício 3

- Problema de Diagnóstico Médico
  - Tarefa T:
  - Medida de desempenho P:
  - Experiência de treinamento E:

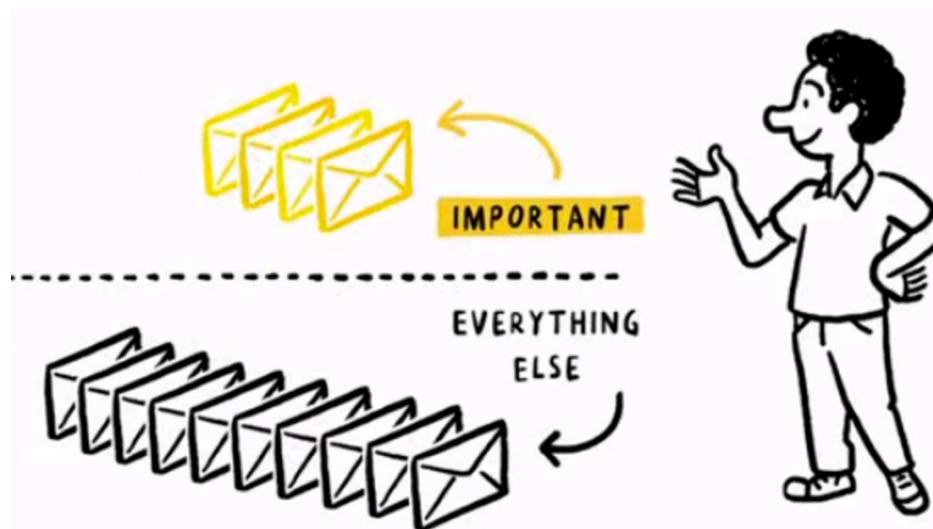
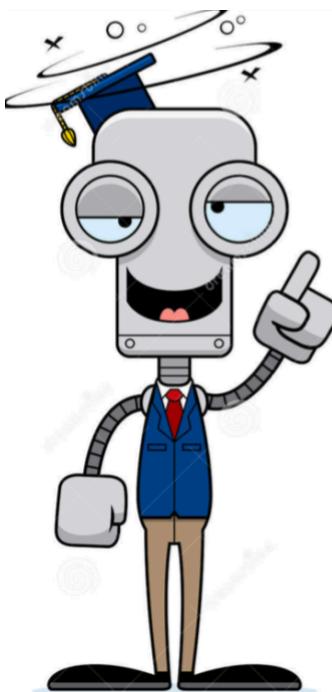
# Paradigmas de AM

- O treinamento de um sistema de aprendizado pode ser:
  - **Supervisionado**
  - **Semi-Supervisionado**
  - **Não supervisionado**
  - **Reforço**

# Aprendizado Supervisionado

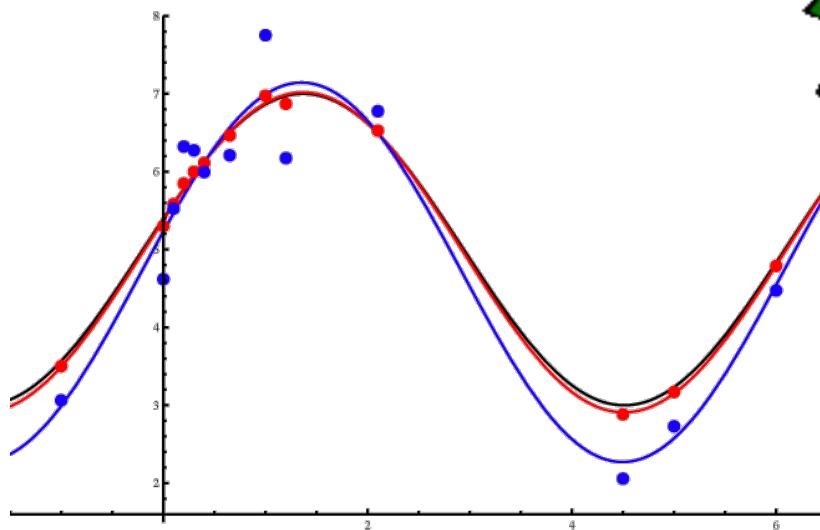
## Guiado por “professor” externo

- Professor possui conhecimento sobre a tarefa
- Representado por conjuntos de pares  $(x, d)$
- Algoritmo de AM gera modelo que busca **reproduzir comportamento do professor**
- Parâmetros do modelo são ajustados por apresentações sucessivas dos pares  $(x, d)$ : **fase de treinamento**
  - Após o treinamento, o desempenho do sistema deve ser testado com dados não-vistos: **fase de teste**



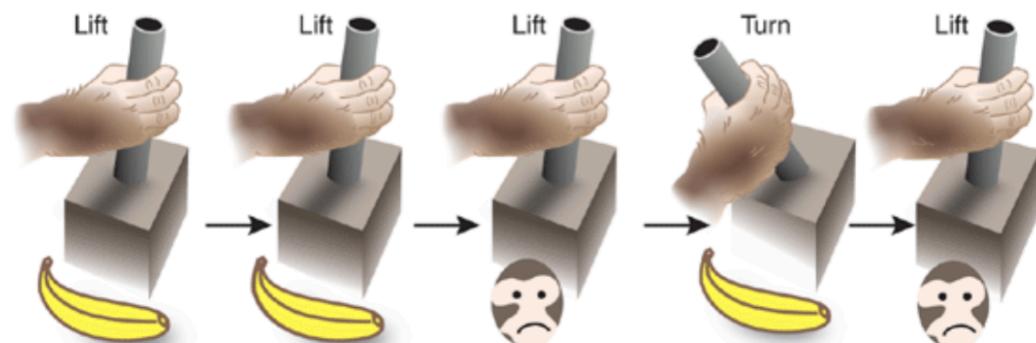
# Aprendizado Supervisionado

- Exemplos de tarefas supervisionadas
  - Classificação de padrões
    - Categorizar objetos
  - Regressão
    - Previsão de valores contínuos



# Aprendizado por Reforço

- Guiado por um “crítico” externo
  - Processo de tentativa e erro
  - Procura maximizar sinal de reforço
- Se ação tomada por sistema é seguida por estado satisfatório, o sistema é fortalecido. Caso contrário, o sistema é enfraquecido (Lei de Thorndike)
- Tipos de reforço
  - Positivo = recompensa
  - Negativo = punição
  - Nulo

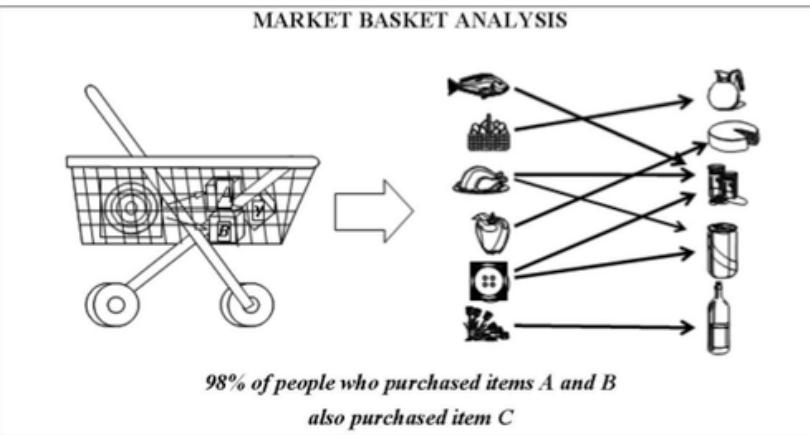
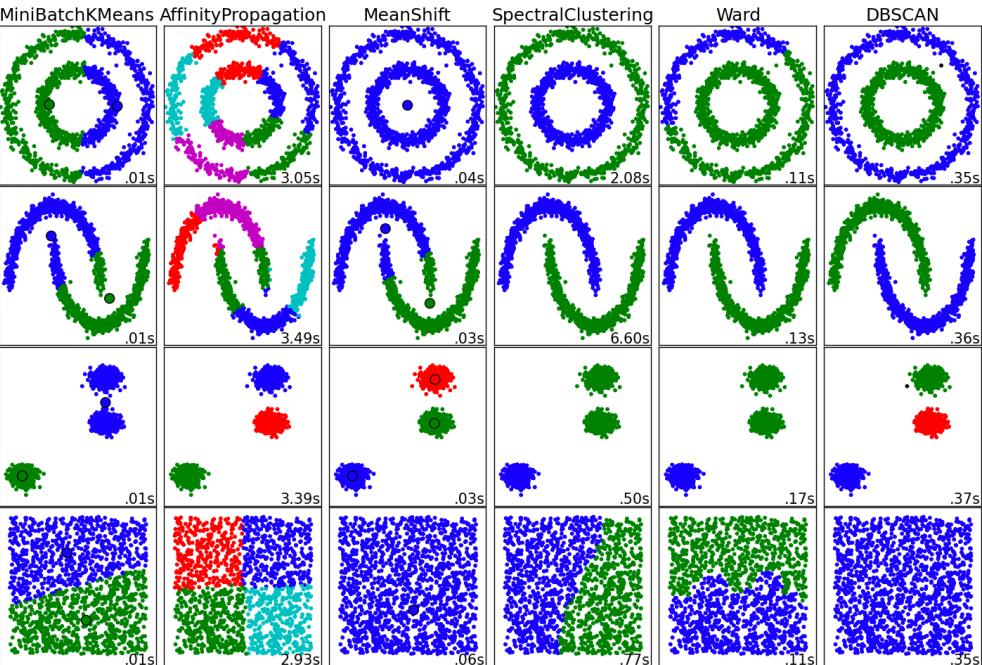
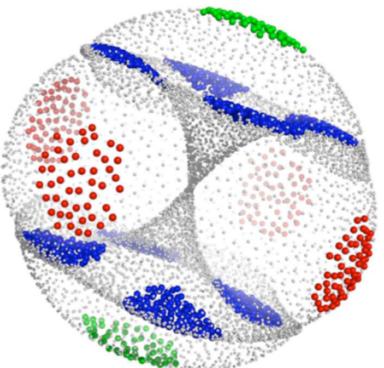


# Supervisionado X Reforço

Treinamento Supervisionado	Treinamento por Reforço
Professor	Crítico
Sistema de <i>Feedback</i>	Sistema de <i>Feedback</i>
É dito o que fazer	Faz e vê o que acontece
Mais rápido	Mais lento

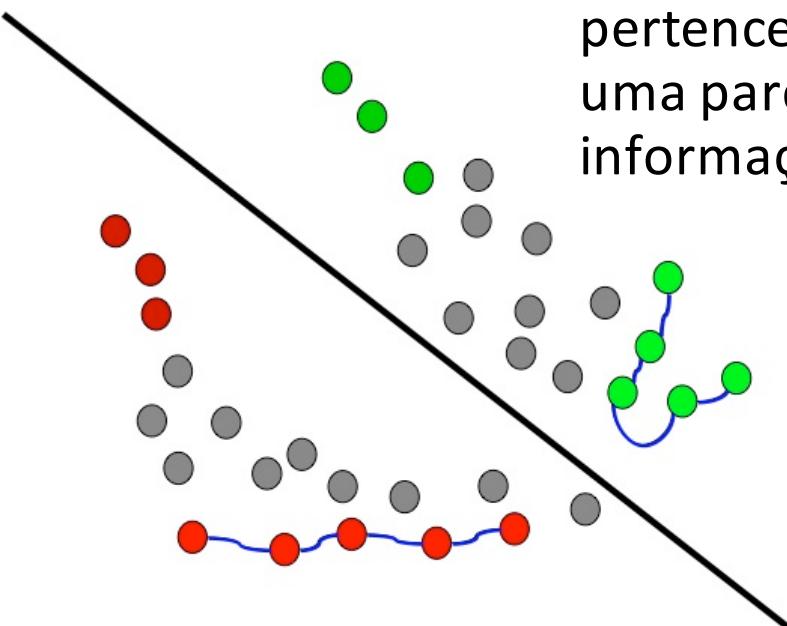
# Aprendizado Não Supervisionado

- Não tem “crítico” ou “professor” externo
- Exemplos:
  - Clustering: descobre categorias automaticamente
  - Associação: descobre relacionamentos entre variáveis
  - Quantização: sumariza dados em grãos automaticamente
  - Redução de dimensionalidade



# Aprendizado Semi-Supervisionado

- Professor externo apenas para parte dos exemplos de treinamento
  - Exemplo:
    - Web mining: usuários podem rotular páginas como pertencentes a determinadas categorias, mas apenas uma parcela ínfima de webpages teria essa informação associada



# Projetando um Sistema de Aprendizado

- Devem ser especificados:
  - Tipo exato de conhecimento a ser aprendido
    - **Função Alvo**
  - Uma representação para o conhecimento adquirido
    - **Modelo de representação do conhecimento**
  - Um mecanismo de aprendizado
    - **Técnica de aprendizado**

# Função Alvo

- Estabelece qual conhecimento será aprendido
  - e permite verificar quão bem ele foi aprendido
- Exemplos:
  - Função discriminante entre categorias (classes)
  - Função de similaridade intra grupos

# Escolha da Função Alvo

- Exemplo:
  - Aprender a diagnosticar paciente de diabetes
    - Função = mapeamento das características dos pacientes para os valores (classes) “diabético” e “não diabético”
    - Como aprender a função?
      - Ajustá-la aos dados disponíveis
    - Como determinar o desempenho da função aprendida?
      - Verificar quantos pacientes ela diagnostica corretamente

# Modelo de Representação do Conhecimento

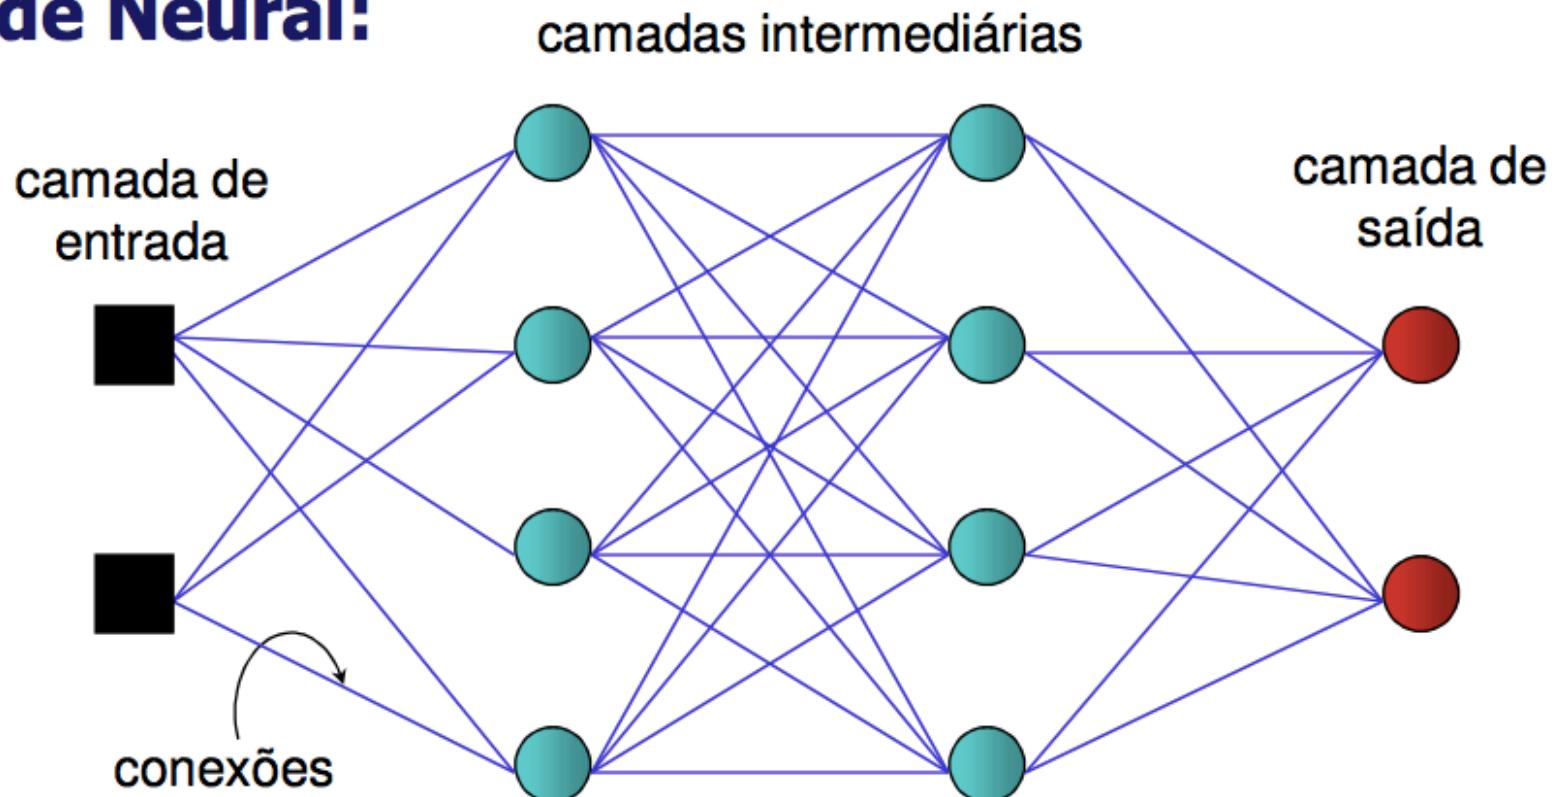
- Modelos Matemáticos
  - Regressão linear / logística
  - Redes Neurais
  - Máquinas de Vetores de Suporte, ...
- Modelos Simbólicos
  - Árvores de Decisão
  - Regras em lógica proposicional ou de 1<sup>a</sup> ordem
  - Redes Semânticas, ...

# Modelo de Representação do Conhecimento

- Modelos “Lazy”
  - K-NN
  - Raciocínio Baseado em Casos (CBR), ...
- Modelos Probabilísticos
  - Naïve Bayes
  - Redes Bayesianas
  - Misturas de Gaussianas
  - Modelos de Markov Escondidos (HMMs), ...

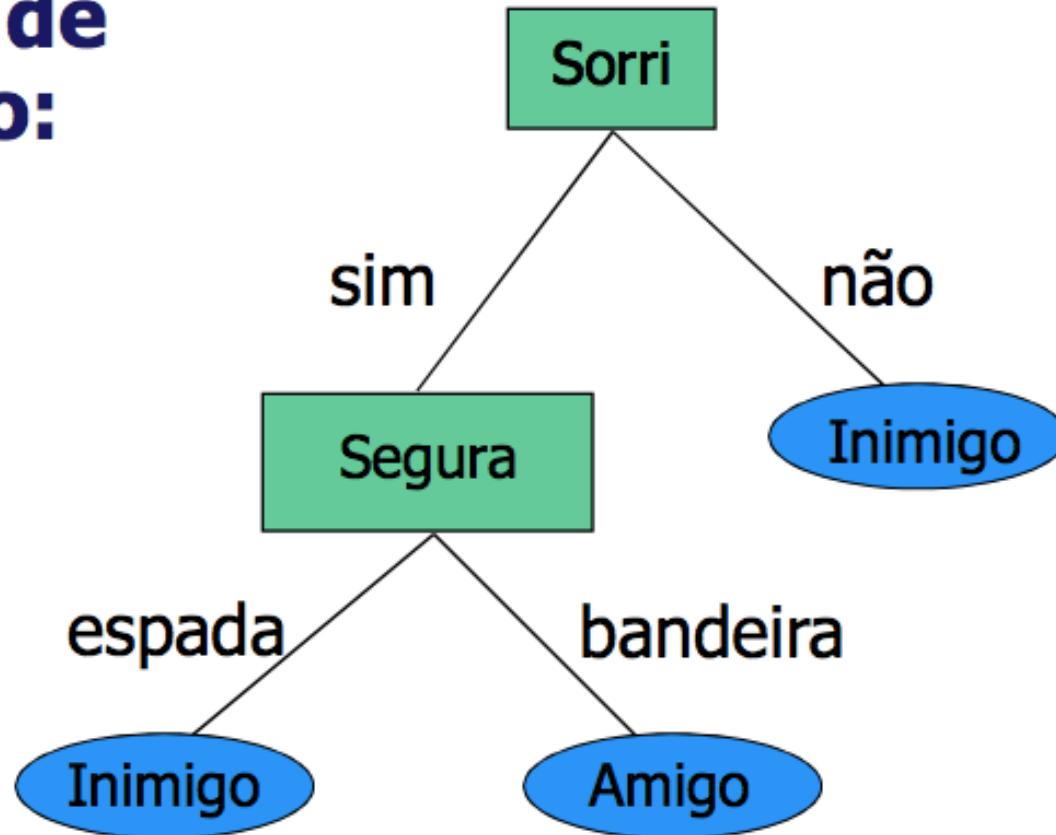
# Exemplos de Modelos

## Rede Neural:



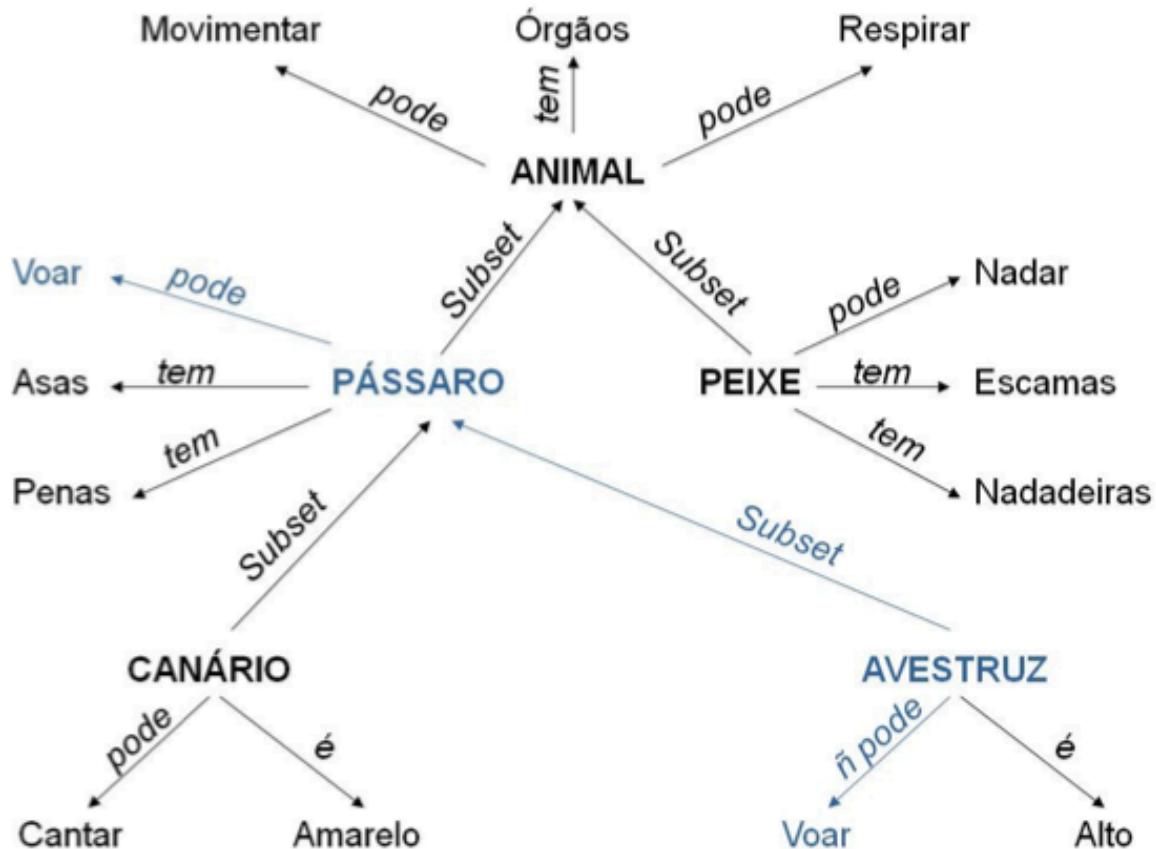
# Exemplos de Modelos

## Árvore de Decisão:

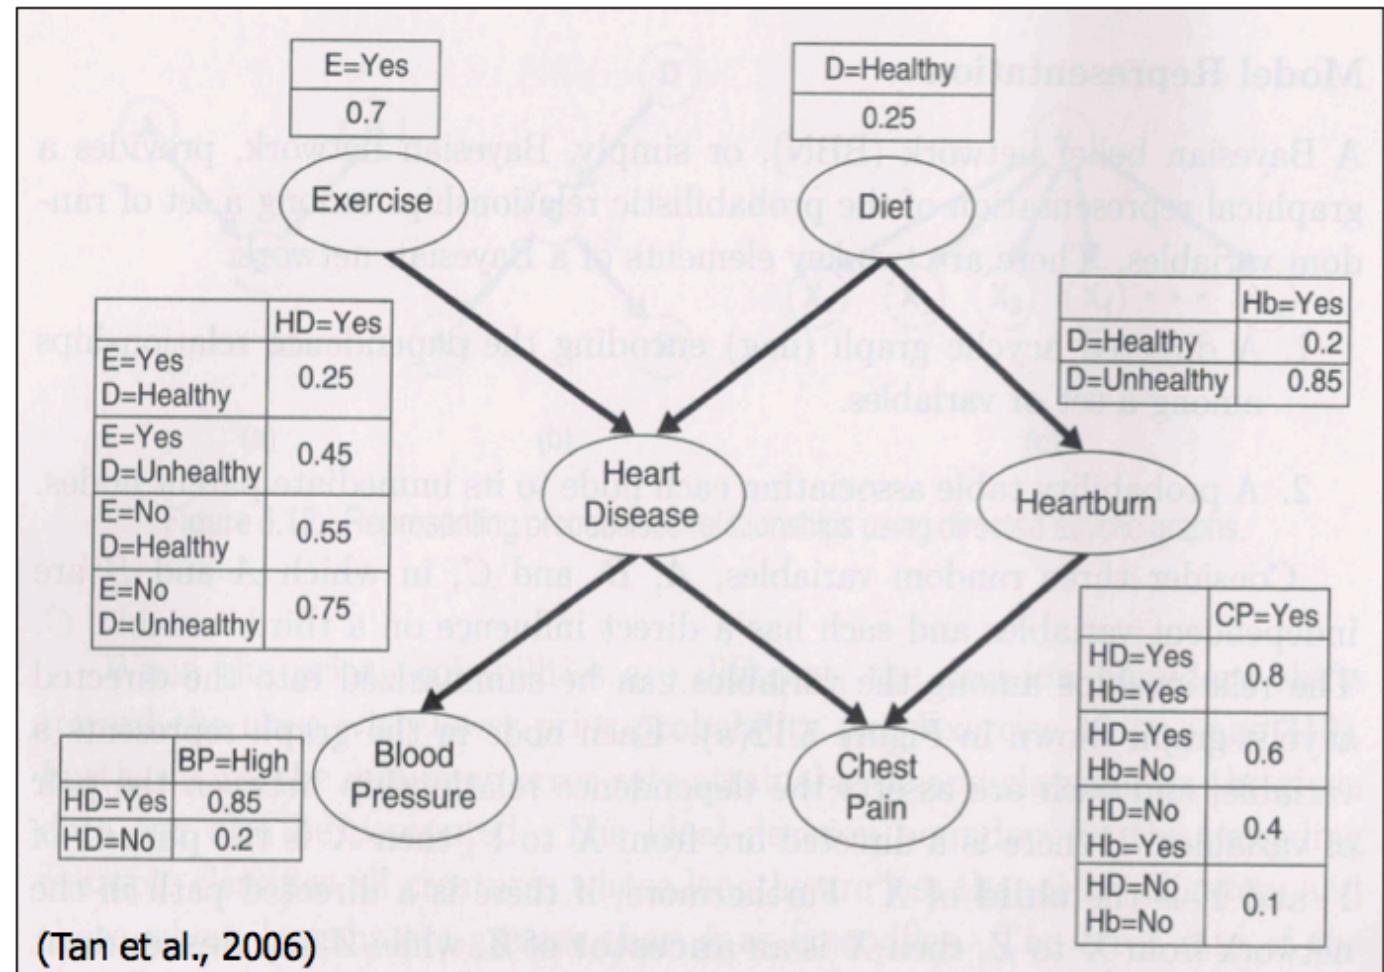


# Exemplos de Modelos

## Rede Semântica:



# Rede Bayesiana:



# Técnicas de Aprendizado

- Dado um tipo de modelo, uma função alvo e um conjunto de exemplos de treinamento, é preciso algum mecanismo para obter um modelo específico que represente bem a função alvo
  - Esse mecanismo consiste fundamentalmente de uma **técnica de busca**
    - Busca-se, no espaço de modelos plausíveis de um determinado tipo, aquele que melhor represente a função alvo



# Técnicas de Aprendizado

- Algoritmos Baseados em Gradiente
  - Regressão linear/logística, redes neurais, ...
- Algoritmos baseados em Programação Dinâmica
  - HMMs, ...
- Algoritmos baseados em Divisão e Conquista
  - Indução de árvores e regras de decisão
- Algoritmos baseados em Probabilidades
  - Naïve Bayes, Redes Bayesianas, ...
- Algoritmos baseados em Computação Evolutiva
  - Aplicável a vários modelos (ver artigos do professor!!)
- ...

# Modelos, Técnicas e Bias Indutivo

- Cada tipo de modelo é mais apropriado para determinada classe de problemas
  - É parte **importante** do estudo de AM aprender a identificar os cenários mais apropriados para cada modelo e técnica de aprendizado
- O modelo e a técnica estabelecem algo **fundamental** em Aprendizado de Máquina:
  - Bias Indutivo

# Bias Indutivo

- Informalmente, o bias indutivo de um sistema de AM é uma tendência a privilegiar um dado conjunto de hipóteses em detrimento a outras
  - Assuma que “hipótese” neste caso se refere a uma realização (ou instanciação) particular de um modelo para aproximar uma determinada função alvo

# Informações Úteis

- Repositório de Dados na Web
  - UCI data repository
    - <http://archive.ics.uci.edu/ml/>
- MOOCs
  - Machine Learning (Coursera – Andrew Ng)
    - <https://www.coursera.org/learn/machine-learning>
  - Data Mining with Weka
    - <https://weka.waikato.ac.nz/explorer>
  - Neural Networks (Coursera – Geoffrey Hinton)
    - <https://class.coursera.org/neuralnets-2012-001>

# Informações Úteis

- Weka
  - <http://www.cs.waikato.ac.nz/ml/weka/>
- Scikit Learn (Python)
  - <http://scikit-learn.org/>
- Matlab Toolbox for Pattern Recognition
  - <http://www.prtools.org>
- R
  - <http://cran.r-project.org/>

# Informações Úteis

- Tom Mitchell's webpage
  - <http://www.cs.cmu.edu/~tom/>
- Kdnuggets
  - <http://www.kdnuggets.com/>
- Perfis a seguir no Twitter
  - Carla Gentry
    - @data\_nerd
  - Gregory Piatetsky
    - @kdnuggets
  - Deeplearning4j
    - @deeplearning4j
  - Nando de Freitas (Prof. Oxford e Cientista GoogleMind)
    - @NandoDF
  - Yann LeCun
    - @ylecun

# Informações Úteis

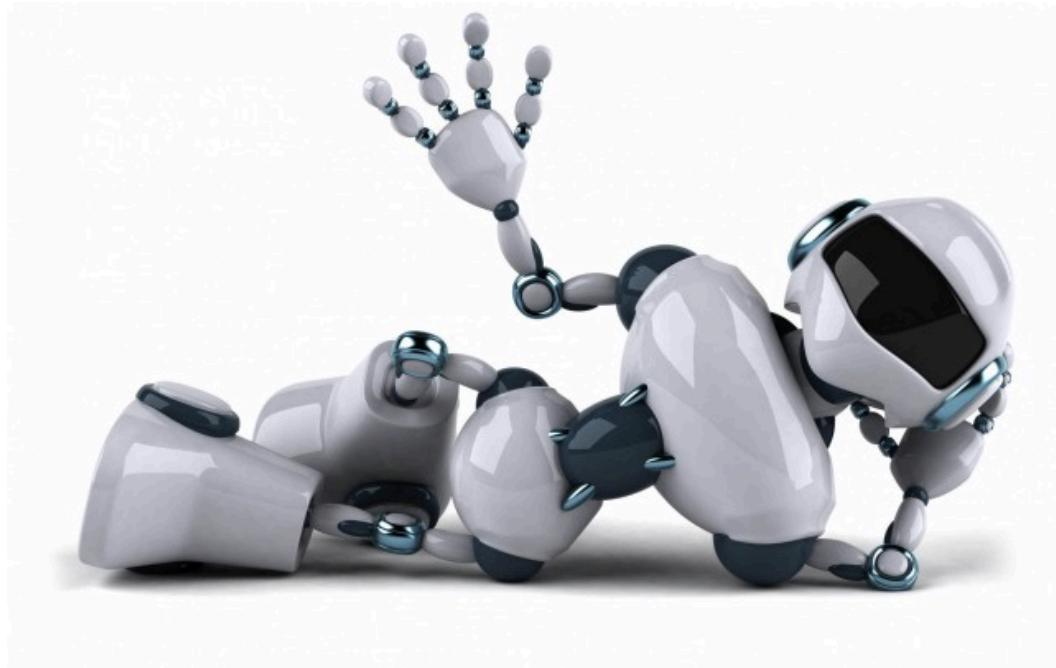
- Journals
  - Machine Learning (Springer)
  - Journal of Machine Learning Research
  - IEEE Transactions on Pattern Analysis and Machine Intelligence
  - Information Sciences (Elsevier)
  - Data Mining and Knowledge Discovery (Springer)
  - Pattern Recognition (Elsevier)
  - Neurocomputing (Elsevier)
  - IEEE Transactions on Neural Networks and Learning Systems

# Informações Úteis

- Conferences
  - ICML (International Conference on Machine Learning)
  - ECML / PKDD (European Conference on Machine Learning)
  - ICDM (International Conference on Data Mining)
  - NIPS (Neural Information Processing Systems)
  - ICPR (International Conference on Pattern Recognition)
  - ICANN (International Conference on Artificial Neural Networks)
  - IJCNN (International Joint Conference on Neural Networks)

# Leituras Recomendadas

- Capítulo 1 (Mitchell 1997)
- Capítulo 1 (Tan et al. 2006)
- Texto sobre bias indutivo no Moodle



# Créditos e Referências

- Slides adaptados dos originais gentilmente cedidos pelos Profs. André Carvalho e Ricardo Campello, do ICMC-USP
- TAN, P. N. STEINBACH, M. KUMAR, V. **Introduction to Data Mining**. Addison-Wesley, 2005. 769 p.
- Mitchell, T. **Machine Learning**. McGraw-Hill, 1997. 432 p.